日経BP 学生AIリーダーズ大賞2026　最終審査（自然科学部門）

AIの発見をAIに反証させる自己対戦型自律実験

製造公差にロバストなスーパーキャパシタ充電制御則の獲得と16バイトへの蒸留

近藤 悠太

2026年10月29日　ステーションコンファレンス万世橋

自己対戦による充電則のロバスト化

問題　**AIが見つけた最適な充電則が、製造ばらつきの内側で安全制約に違反**

提案　**発見AIと反証AIを対戦させる、自己対戦型の自律実験**

違反した個体を学習用の個体（学習個体）に加えて再探索

公差の範囲から無作為に選んだ24個体での違反

7個体 → 0個体

応募後：生成AIが違反コーナーを提案

10／10回

無作為の8個が違反を含む確率 1.6%
違反は1024コーナー中2

数値はすべて回路シミュレーションの値で、実機では未検証

最適解が違反する仕組み

条件は数千通り以上、1条件の実測は分単位
AIによる条件探索（自律実験）

最適化は制約の範囲で効率を最大化
解は制約の境界付近に集中

学習個体では安全
ばらつきの内側の別の個体では違反

安全制約に対する余裕（概念図）



横軸：制約の指標（例：突入電流）→ 右ほど大

セル4個の直並列切替による充電

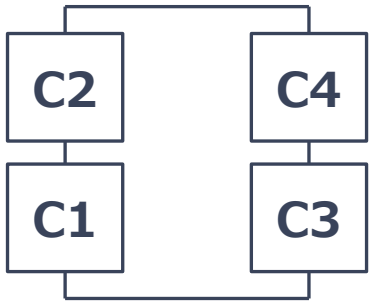


はじめ：4直列



切替
→
1回

切替後：2直列2並列



安全制約（3本）

入力ピーク電流	**1.0 A以下**
切替時の突入電流	**0.5 A以下**
充電時間	**0.28秒以下**

※ セルは20 mF級のスケールモデル

AIが決める値（8個）

切替電圧1・電流の境界3・電流指令4

目的：**充電効率の最大化**

切替を遅らせるほど効率は上がるが、セルの個体差による突入電流は大きくなる

発見AIと反証AIの自己対戦ループ

発見AI

安全制約を満たし、
効率が最大の充電則を探索

ベイズ最適化（ガウス過程）

最適な充電則

違反が見つかる限り反復

違反個体を学習個体に追加

反証AI

充電則が違反する個体を、
公差±10%の範囲から探索

同じ探索器で、探す向きを反転
人が置いた初期点（コーナー4点）
応募後は生成AIが提案（スライド11）

実験はすべて LTspice 上で実行し、**条件の設定から結果の回収までを Claude が自動化**

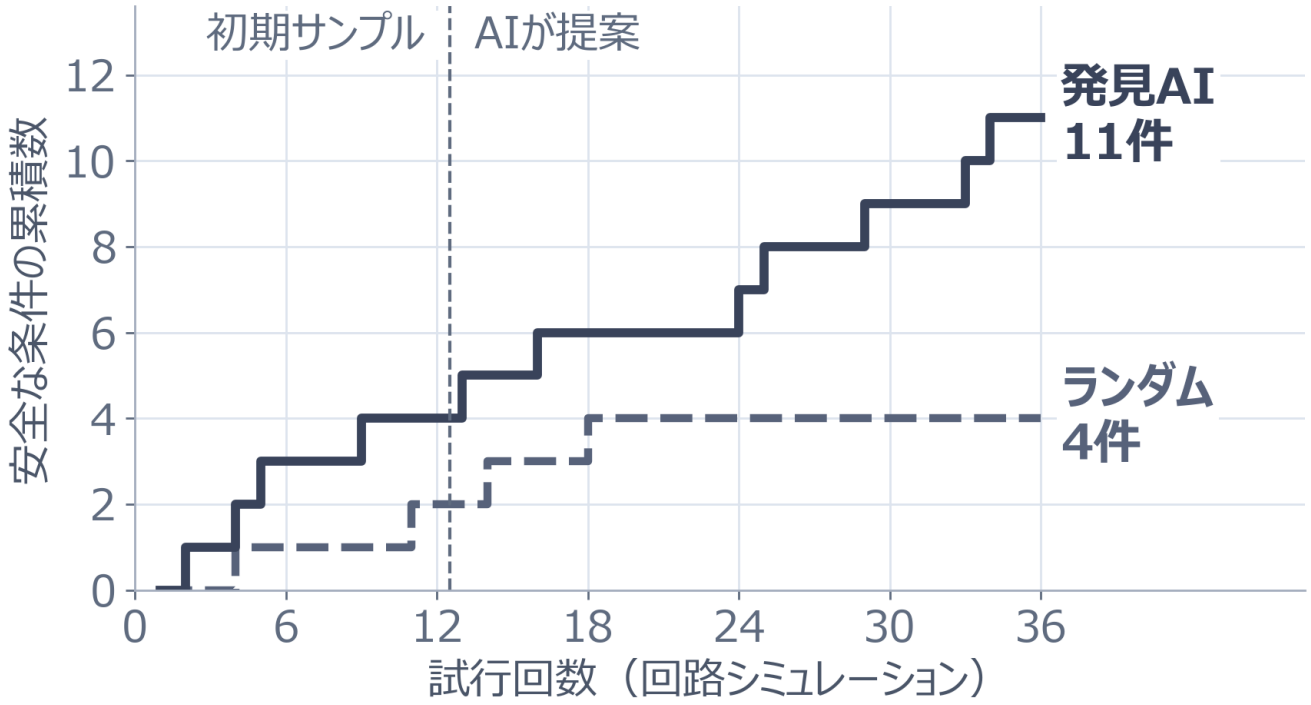
終了条件：評価20個体で違反が見つからないこと
ロバスト最適化・敵対的訓練そのものは、機械学習では既知の手法

既知の最悪条件探索を、自律実験のループに反証AIとして組み込んだ

工程ごとのAIと人の分担

	工程	AIに任せたこと	なぜAIか	人が担ったこと
1.	**発想** **生成AI**	異分野の仕組みを 回路と実験に読み替え	**異分野と回路の原理を 並べて比較**	採用する原理の選択
2.	**発見** **探索AI**	次に試す充電条件の提案	**8変数の組合せを、 36回の試行で探索**	制約の設計 充電時間の制約を追加
3.	**反証** **探索AI・生成AI**	最適解が違反する 個体の探索	**人手で選んだ3個体では、 突入電流の違反を見逃し**	違反の仕組みを 物理で解釈
4.	**実装・実行** **生成AI**	回路モデルと探索コードの 実装、LTspice の実行	**171本超を無人で実行 PC1台で約1.4時間**	数値の再実行と 一次資料の確認

ランダム探索と比べた安全な条件の件数



応募時の実験（36回中、左の図）

11件 対 **4件**

乱数の種を変えた5回（応募後）

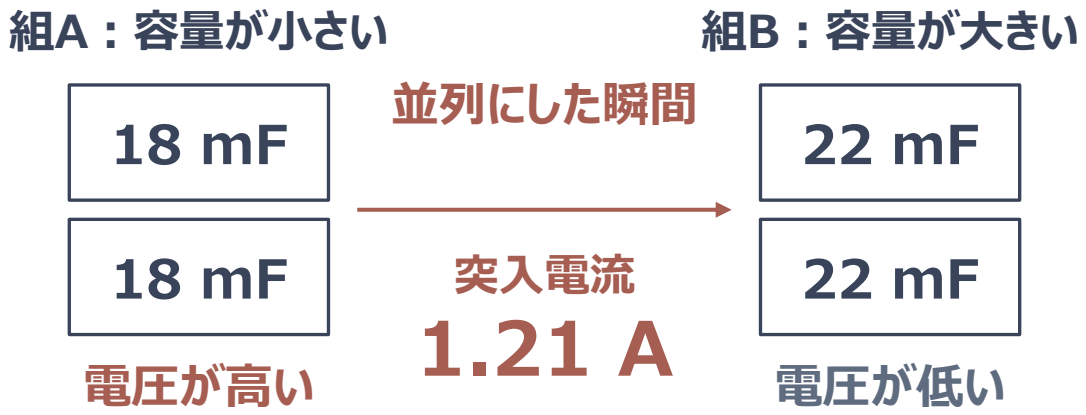
平均 **7.8件** 対 **5.0件**

5回中4回で発見AIが多く、1回は逆転

応募書の2.8倍は種1通りの結果で、種を変えた5回の平均は約1.6倍だった

公差の内側での安全制約の違反

反証AIの最悪の個体（人が置いた初期点）



容量の小さい組ほど電圧が上がるため、
切替が遅いほど、組の間の電圧差が拡大

同じ最適解を、3つの方法で検査した結果

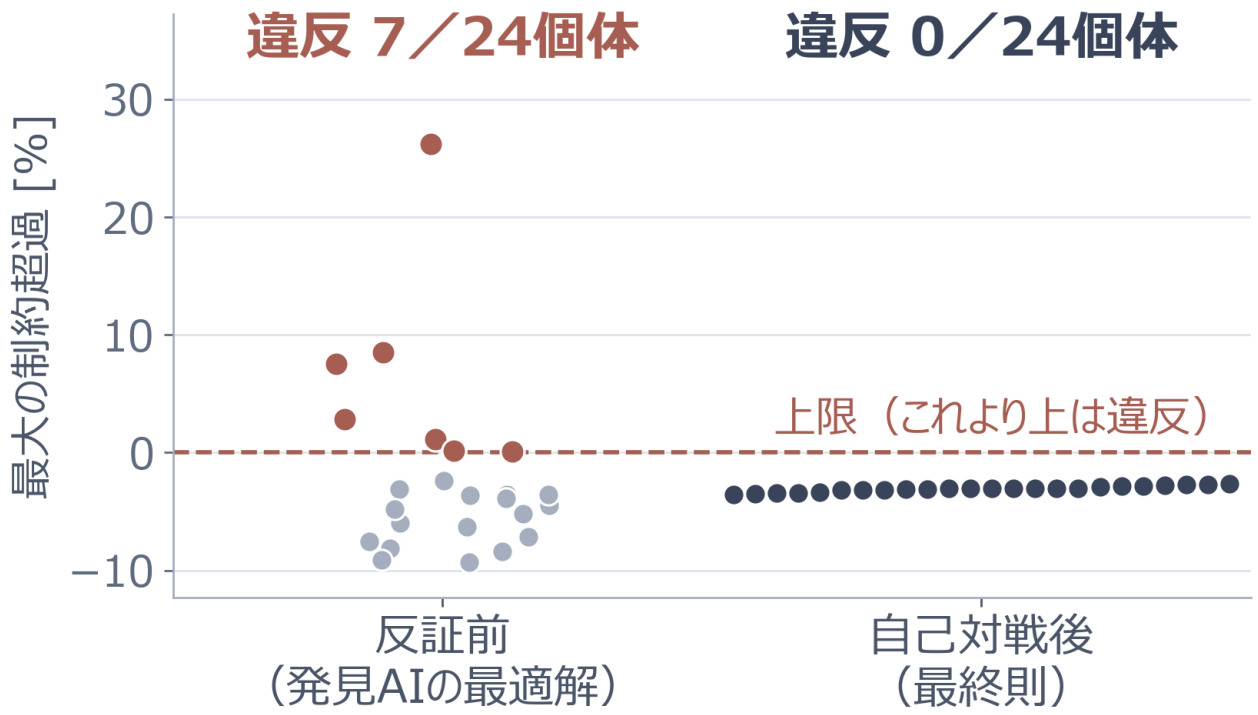
人手（学習に使っていない3個体）
突入電流の違反を見逃し
最大 0.49 A（上限 0.5 A）

無作為（公差の範囲から24個体）
7個体で違反 上限超過 最大 +26.2%

反証AI（評価20個体）
+142.1% 上限超過（上限の2.4倍）
ベイズ最適化分だけでも +115.9%

人手では突入電流の違反を見逃し、無作為では違反の大きさを過小評価した

最適解と最終則の無作為24個体での違反



ラウンド1	**攻撃が成功（+142.1%）**
ラウンド2	**評価20個体で違反なし**

代償：充電効率が**約1.2ポイント低下**

95.86% → 94.64%

1個体（学習個体A）での値

※ 評価20個体での結果で、全数の保証ではない

検証で見つけた問題と対処

1. AIが提示した設計

回路とコードの不具合

6件

うち5件は、実行して得た
数値の不自然さから発見

一覧は付録A

2. 反証AIが見つけた不備

(1) 防御の失敗

違反個体を
加えるだけの再探索は
36候補すべて実行不可能

電荷保存則から候補を逆算

(2) 仕様の不備

満充電の判定が不適切

判定を直し全実験を再実行

3. 自分の主張の見直し

モデルの欠落

内部抵抗を入れず
突入電流を3倍に過大評価

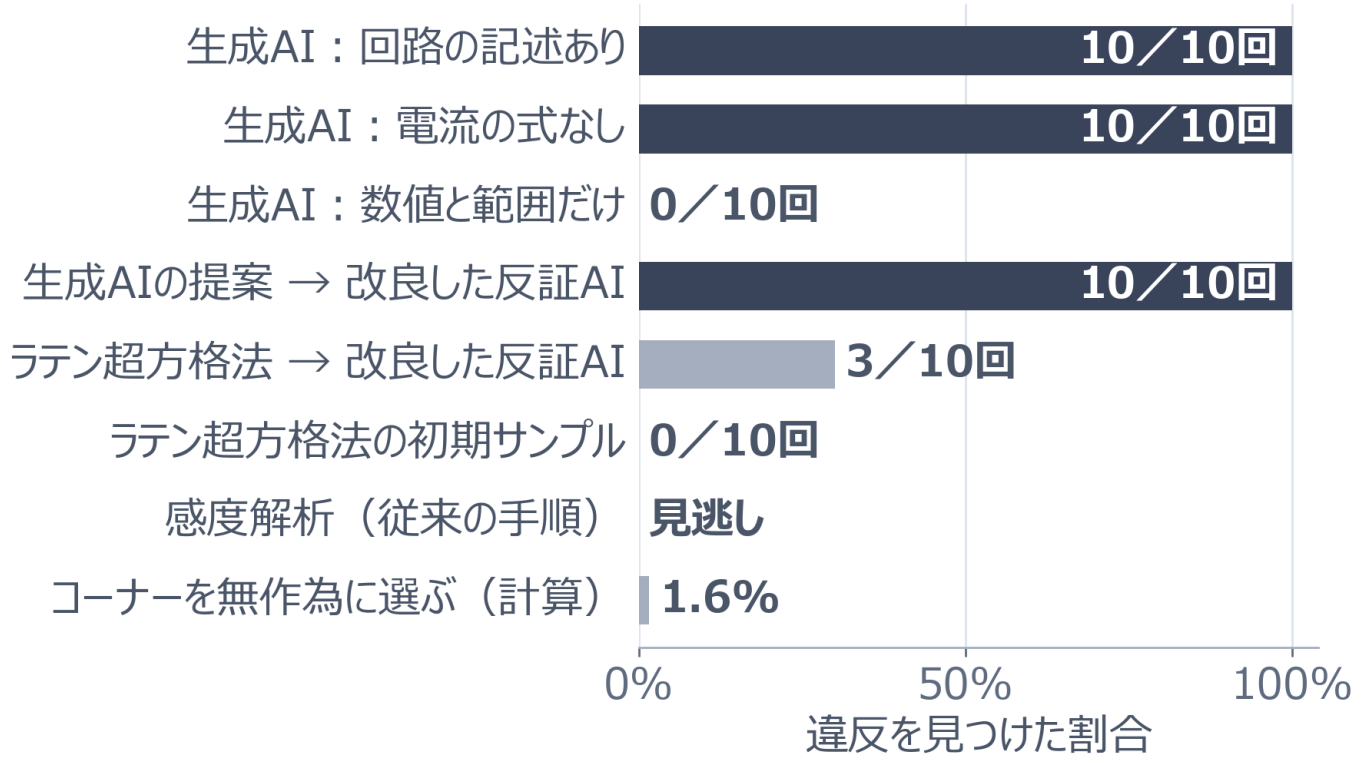
全実験を再実行

応募書の再検証

主張43件中3件が不一致
2.8倍は種を変えると約1.6倍

主張を訂正（スライド7）

生成AIによる違反コーナーの提案



改良した反証AI＝制約ごとに攻め、学んだ傾きでコーナーを選ぶ（応募後に作成）

対象：応募時の最終則

1024コーナー中、違反は2つ

ばらつき10次元の全探索で確認済み

生成AIに渡したもの

回路・充電則・制約の記述

結果は入力せず、独立に10回
組分けを入れ替えても10回中10回

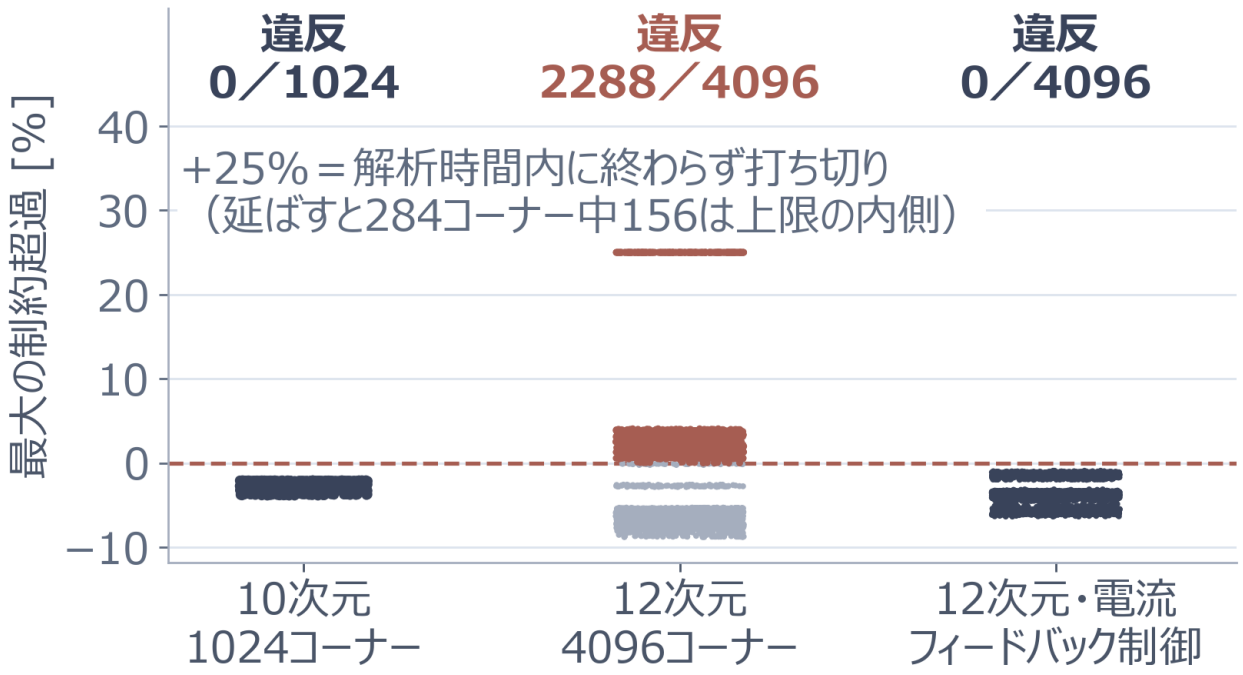
応答の理由を全探索で採点（30回）

突入電流の主張 99.5%

入力ピーク電流 35%・充電時間 56%
範囲外の定数の順位は主要評価項目で
有意でなく、副次評価項目で弱い一致

生成AIは違反コーナーを提案に含めたが、理由の正しさは制約ごとに分かれた

制御の構造を変えた12次元の検証



10次元で直した則にインダクタンス・巻線抵抗 ±20%

違反 2288／4096

切替電圧を絞った112則の探し直しでも見つからず

制約の測り方：違反の9割近い入力ピーク電流

過渡 0.64 A が常に上乗せ

16コーナーで分解、差は巻線抵抗の側

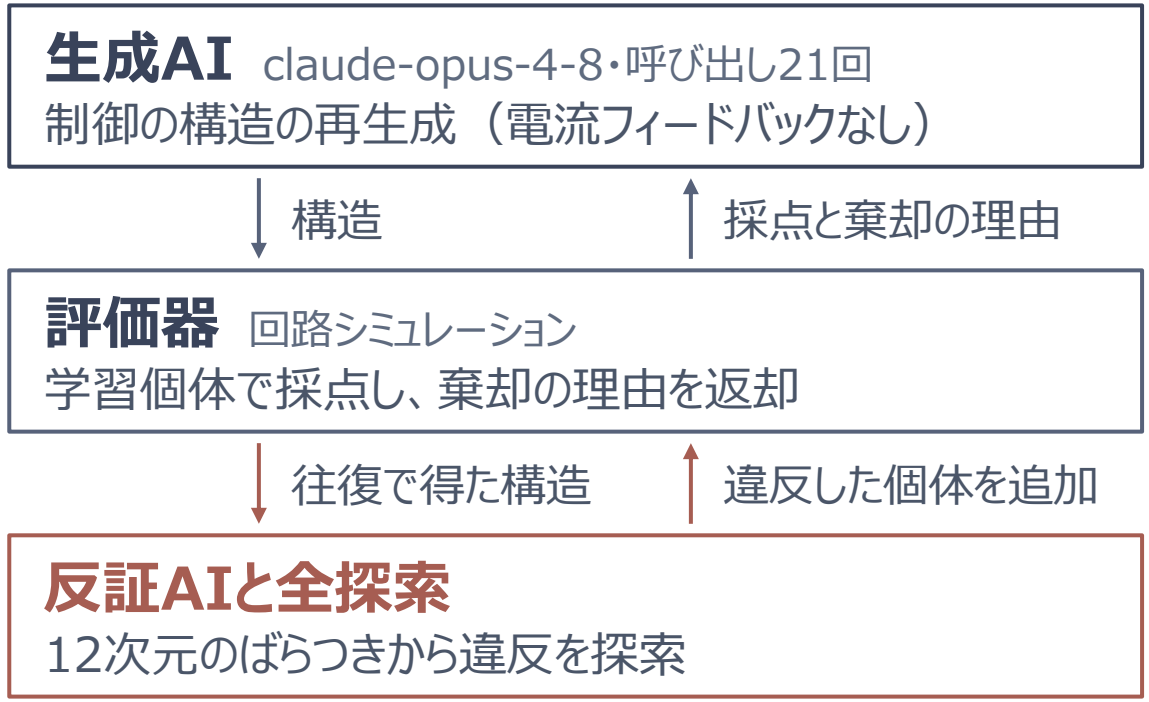
則はそのまま、電流フィードバック

違反 0／4096

最も厳しい値で上限の0.9%手前

電流を誤差なく測るモデル。オフセット（約 +0.011 A・−0.014 A）を超えると最も厳しいコーナーで上限超過
設計書のセンサの目標 ±0.024 A では不足。制御の定数は時間を縮めた回路モデルで校正

生成AIに設計させた構造の反証



条件の形は仕様から読める状態で、
答えを見ていない別の生成AI 2つが文面から推測できた
突入電流の式と、同じ量を表せる語彙を渡した
往復の手順は10月に公開された量子回路の研究から借りた

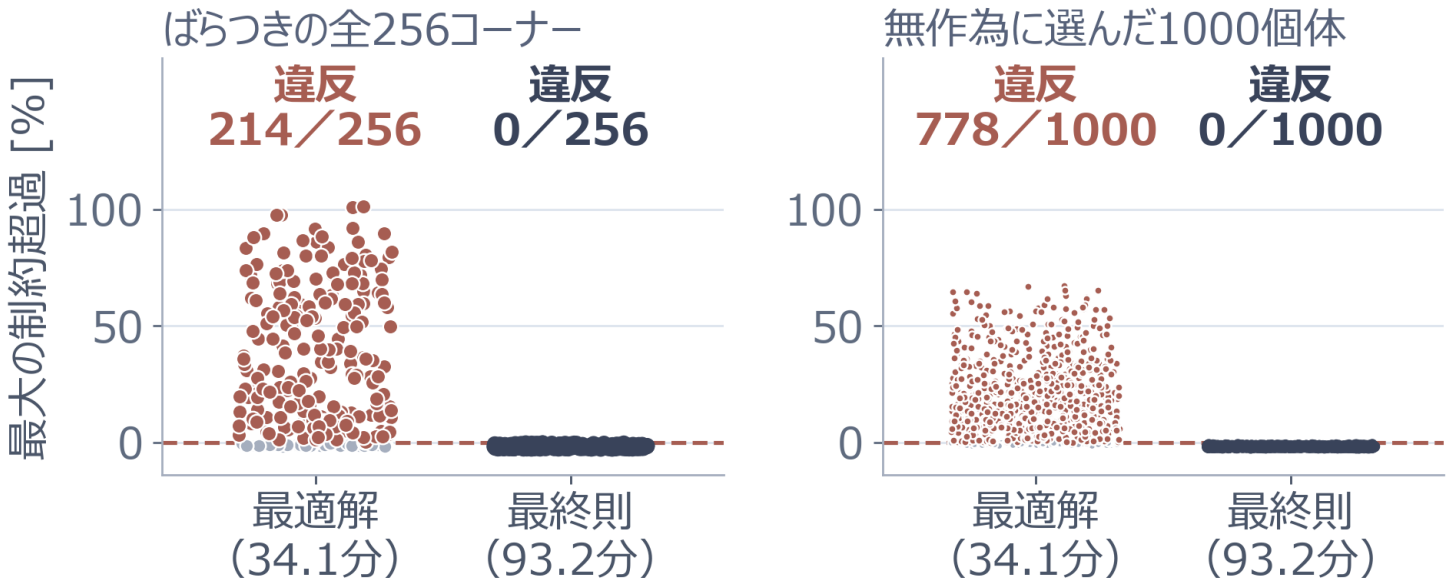
学習6個体での採点
3方針のうち2つが適合（1・2回目）
組の電圧差で第1段を止める条件を使用

反証AIの攻撃（6回目の構造）
違反 5／5回
巻線抵抗 0.18 Ω の個体の充電時間

全探索（8回目の構造・計算値の幅を引いて判定）
不適合 116／4096
巻線抵抗 0.12 Ω の入力ピーク電流で再現

往復の外：10次元の則＋同じ形の条件＋電流フィードバック
違反 0／4096（オフセット0）
許容範囲 約 −0.010～+0.029 A（29対象・補間）
設計書の目標の下端 ±0.024 A に少ない向きで不足

リチウムイオン電池の急速充電への転用



発見AIの最適解（34.1分）

違反 214／256

温度かリチウム析出の制約に違反

自己対戦（2ラウンド）の最終則

違反 0／256・0／1000

代償：充電時間 2.73倍（93.2分）

乱数の種を変えると85.6～99.1分

条件 PyBaMM の電気化学モデル・LG M50・充電率（SOC）10～80%・4段の定電流・
ばらつき8変数（環境温度15～35 ℃など）

シミュレータの値で実電池は未検証

交換電流密度は、元の範囲では最も遅い充電でも析出の制約を超えるため、制約を満たせる範囲に限定

観点ごとの成果

観点	示したこと	根拠となる数値
AI活用の工夫	既知の最悪条件探索を反証AIとして 組み込み、違反個体を学習に戻すループ	**応募時：発見AIと同じ探索器** **＊10次元で見逃し、生成AIの候補を追加**
従来の検査との比較	人手と無作為の検査が見逃した、 または過小評価した違反を解消	**違反 7 → 0（24個体中）** **＊生成AI 10／10回（無作為なら1.6%）**
AI出力の検証	実行と反証で確かめ、 自分の主張も再実行して訂正	**＊2.8倍 → 約1.6倍（種を変えて再実行）** **＊制約の測り方・生成AIの理由も反証**
規模と応用	1人・PC1台で実行できる手順、 則は16バイト（4次元・±10%で違反0）	**＊12次元：違反 2288 → 0** **＊電池：違反 214 → 0（256コーナー中）**

AIが見つけた最適解は、採用する前に反証する必要がある

反証の対象を、制約の測り方・生成AIの理由・制御の構造にも広げる

＊は応募後の追加検証（未提出）。数値はシミュレーション値。制御の定数は回路モデルで校正
＊12次元は電流フィードバックの4096コーナー（電流を誤差なく測るモデル。オフセット 約 +0.011・−0.014 A 超で上限超過）

AIが提示した設計の不具合6件

	実行して分かった症状	原因	対処
1.	**入力ピーク電流が83 A**	同期整流のデッドタイムの論理が逆 上下のMOSFETが同時にオン	両エッジにデッドタイムが入る 条件式に修正
2.	**セル電圧0.14 Vで充電が停止**	デューティ比を固定するとバンク電圧が 平衡し、電流がゼロ	デューティ比をバンク電圧から算出
3.	**LTspice の収束失敗**	直列と並列の切替を電圧制御スイッチで模擬	解析を切替の前後2本に分割 電荷保存則で接続
4.	**貫通電流が21 A**	デューティ比の指令にスイッチングリプルが混入	指令にRCフィルタを挿入
5.	**充電後のセル電圧が0 V**	完了時にデューティ比0で下側MOSFETが 常時オン（20.8 A）	完了時は両方のゲートを遮断
6.	**充電時間が3.3秒と報告**	測定値の読み取りで時刻と値を取り違え 解析時間は0.2秒	読み取り処理を修正

6件中5件は、AIの説明を読むだけでは検出できず、実行して得た数値の不自然さから発見した

物理から逆算した候補を加えた防御の再探索

起きたこと

違反個体を学習個体に
加えただけの再探索

36候補すべて実行不可能

実行可能領域が、切替電圧の
狭い範囲に限られていたため

→

物理による解釈（人）

4直列の間は全セルの電荷が同じ

組の間の電圧差ΔVは
切替電圧に比例

突入電流＝ΔV÷(2Ron+4ESR)

切替電圧の上限 0.41 V を逆算

Ron：切替スイッチのオン抵抗
ESR：セルの内部抵抗

→

結果

逆算した切替電圧と、
実績のある電流の区間構成を
初期サンプルに追加

47候補中2件が実行可能

いずれも物理から逆算した候補
最終則（切替0.35 V）はその1つ

応募時は物理の候補が最良。種を変えた3回中2回は探索が効率で上回る則を見つけ、最終則になったのは1回（付録I）

反証AIが見つけた満充電の判定の不備

当初の判定

セル1が充電停止電圧 2.20 V に到達

攻撃が見つけた個体では、同じ組のセル2より
容量が大きいセル1の電圧上昇が緩やか

セル1が届く前に、セル2が 2.61 V まで上昇
到達は0.37秒後で、制限時間0.28秒を超過

→

修正後の判定

最も高いセルが
充電停止電圧 2.20 V に到達

過電圧保護と同じ意味の条件

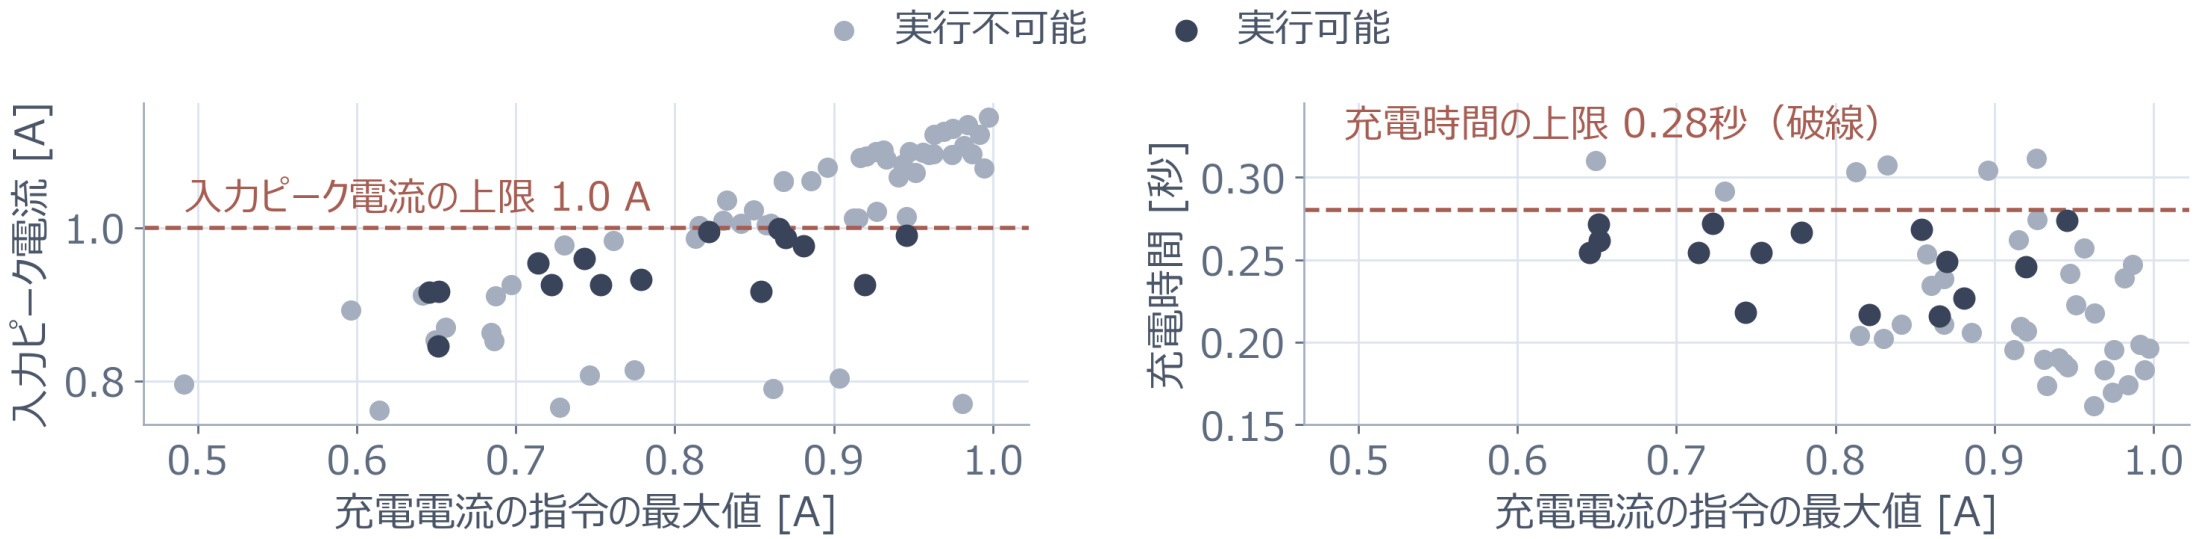
全実験を再実行
旧仕様の実験台帳も、
経緯の証拠として成果物に同梱

見つかった経緯
旧判定の防御で、この個体だけ47候補すべてが実行不可能になり、原因を追跡して判定条件の不備と判明

学習個体Aでの探索の設定と試行の分布

探索空間　8次元（切替電圧／電流を変える境界3つ／各区間の電流指令4つ）
モデル　充電効率と制約3本を、それぞれ独立のガウス過程で近似
獲得関数　改善期待値 × 各制約を満たす確率の積
試行の配分　初期サンプル12点（ラテン超方格法）＋4点ずつ6回＝36回。乱数の種は固定

点＝発見AI 36本（初期12＋提案24）とランダム探索36本の計72本。時間内に満充電へ届かなかった19本は右図になし



電流を上げると入力ピーク電流の、下げると充電時間の上限に当たり、突入電流の上限を超えた候補は0件だった

数値の照合と利用したAI・ソフトウェア

数値の扱い

- **自動の流し込み**
  数値は実験出力のJSONから（一部は直書き）
- **照合（応募時）**
  数値53種が実験出力などにあるかを照合（不明0件）
- **照合（応募後）**
  主張43件を項目ごとに再計算、3件が不一致
- **再現性**
  提出済みの値6個を再実行し、10桁まで一致

利用したAI・ソフトウェア

claude-fable-5	方針の設計、検証手順の立案、最終確認
claude-opus-5	モデル・コードの実装と実行、資料の生成
claude-opus-4-8	応募後の反証の候補、防御側（付録U）
claude-sonnet-5 **claude-haiku-4-5**	応募後の再現の確認（付録U）
Claude Code	上記モデルの利用と、コード実行の自動化
LTspice XVII	過渡解析（バッチモードで自動実行）
PyBaMM 26.9	電池の充電の計算（応募後）
scikit-learn	ガウス過程回帰（NumPy・SciPy 併用）

既知の手法に対する本研究の寄与

既に知られていること

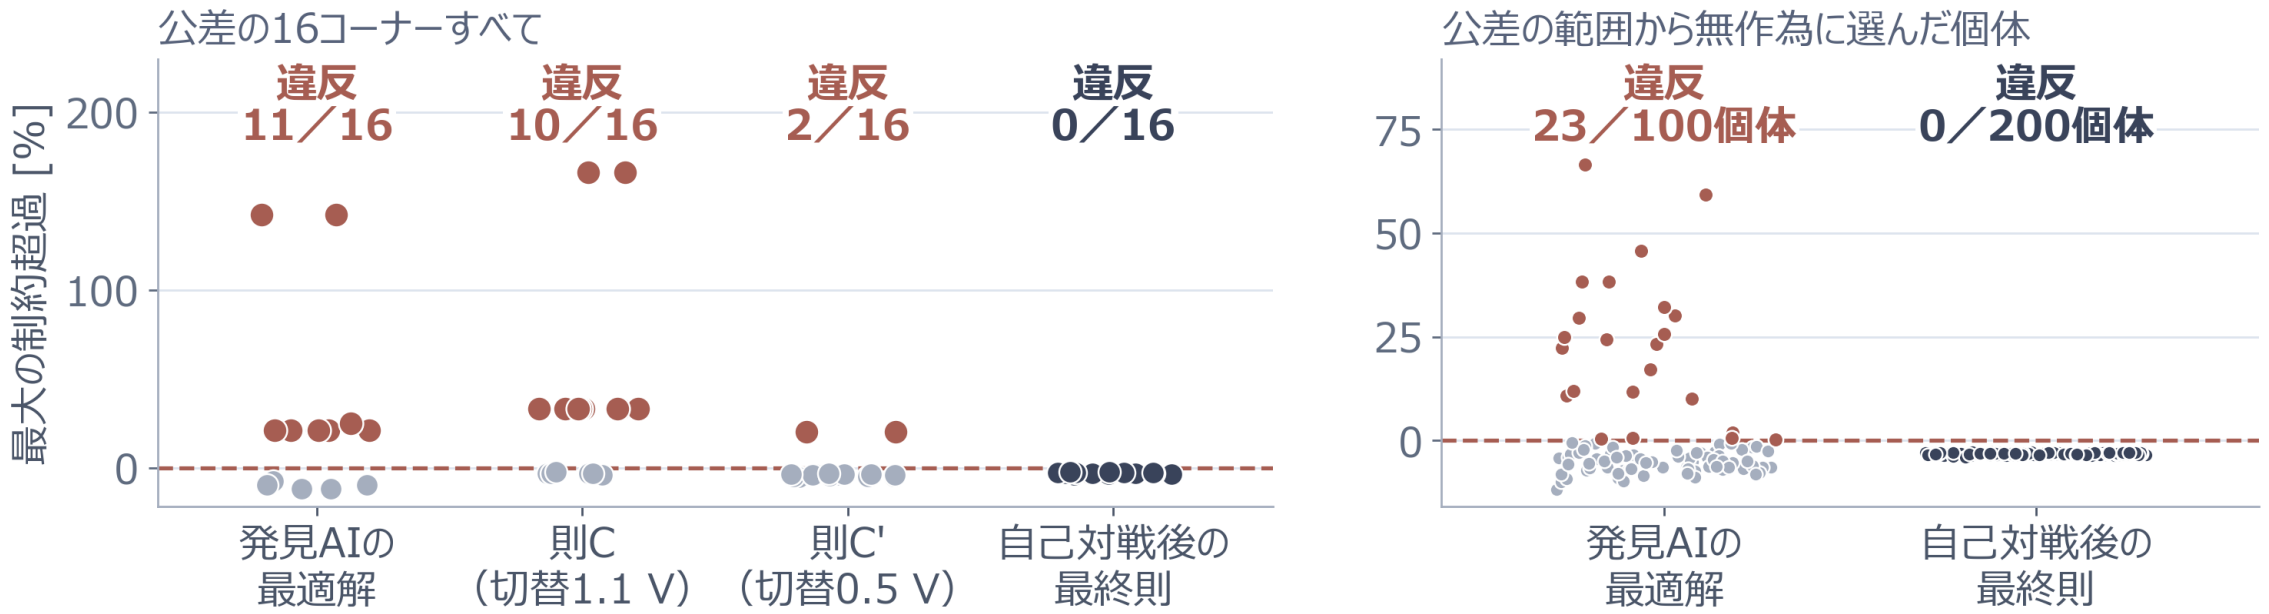
・最悪条件を加えて解き直す反復（相吉・志水 1979）
・ベイズ最適化で最悪条件の探索と設計（Wabersich ら 2015）
・ベイズ最適化による反証（Deshmukh ら 2017、Ghosh ら 2018）
・制約を1つにまとめると隠れる違反（Zhang・蓮尾ら 2019）
・最悪条件の探索（加藤ら 2008、山本ら 2020、阿座上ら 2023）
・生成AIで反例・ベイズ最適化の初期点（LLM-Falsifier、ADO-LLM）
・電池充電のベイズ最適化・反例（Attia ら 2020、Coppola ら 2025）
・仕様が実現できない理由の診断と修復（Ghosh ら 2016）
・自律実験の判定器そのものの誤りの指摘（Leeman ら 2024）
・自律発見での発見側と反証側の競合（DASES、2026）

新しい最適化手法や理論は主張しない

本研究の寄与（調べた範囲で）

・既知の反復を、安全制約つきで
物理系の自律実験に組み込み、
反証AIの見逃しと代償を全探索で測った
・結果を入力せずに、違反しそうな個体を
生成AIに提案させ、全探索の正解と
照合し、反証の初期サンプルに使った
・同じ手順を、電池の急速充電の
シミュレータに移した
・応募後：正解の定義（制約の測り方）、
生成AIの理由、制御の構造も
反証の対象にし、全探索の正解で測った

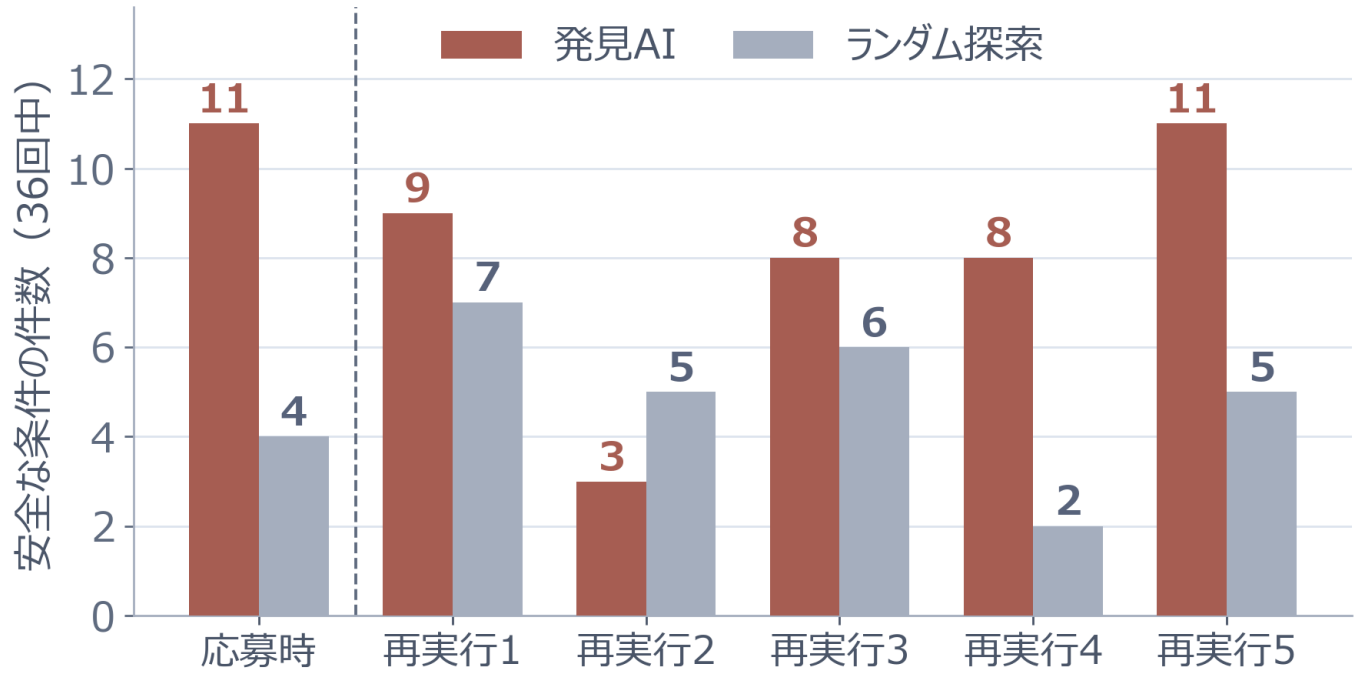
16コーナーと200個体での最終則の違反数



最終則で内部抵抗を一律に変更	−40% **違反 2コーナー**	−20% **違反なし**	基準 0.05 Ω **違反なし**	+20% **違反なし**	+40% **違反なし**

則C・則C'＝人手で調整した則（切替1.1 V・0.5 V）。応募時と付録K の攻撃対象は則C'

安全な条件の件数での発見AIの優位（6回中5回）



応募時を含む6回の合計（各36試行）
50件 対 **29件** 約1.7倍

再実行5回のみ
39件 対 **25件** 約1.6倍

最良の効率が発見AIのほうが高かった回
3／6回

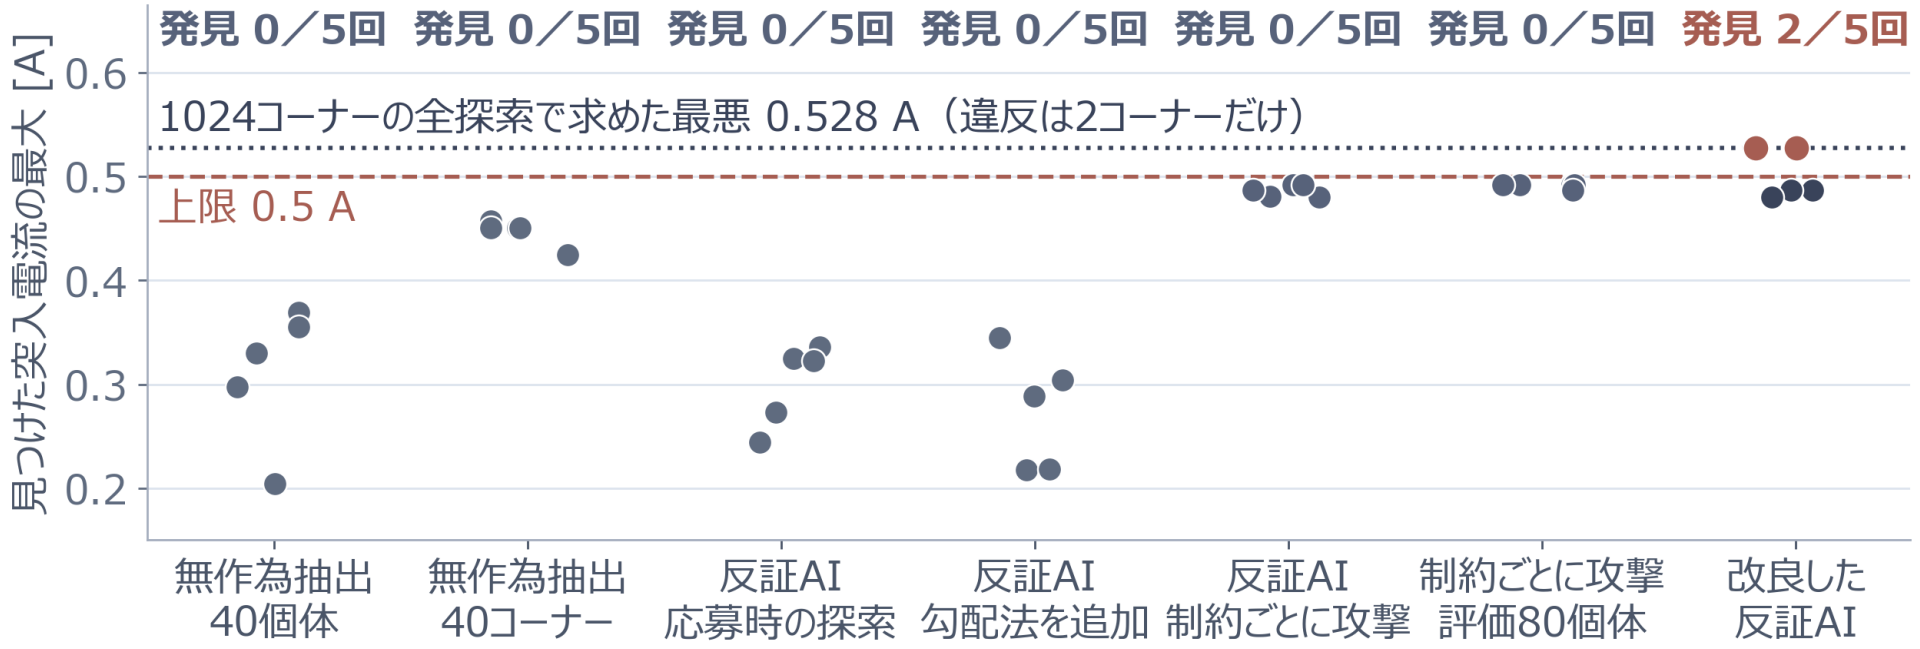
応募書の2.8倍は種1通りの結果で、種を変えると約1.6倍に縮み、1回はランダム探索のほうが多かった

応募時と種を変えた3回の自己対戦

	応募時	再実行1	再実行2	再実行3
ラウンド数	2	3	2	2
最終則の出どころ	物理の候補	物理の候補	物理の候補	探索が見つけた則
学習個体Aでの効率 [%]	94.64	94.64	94.64	94.75
切替電圧 [V]	0.35	0.35	0.35	0.35
16コーナーでの違反	0／16	0／16	0／16	0／16
無作為の個体での違反	0／200	0／100	0／100	0／100

再実行1：防御で探索が見つけた則が次の攻撃で再び違反（+0.5%・充電時間）、1ラウンド追加した後の最終則は物理の候補

上限に近いが違反しない制約への評価回数の偏り



事前に決めた方法：左から4列。応募時の最終則（10次元）を評価40個体で攻撃し、5回とも見逃し
後から加えた方法：右の3列。制約ごとに攻撃（評価40・80個体）、改良した反証AI

左の反証AI2種は、図にない入力ピーク電流（上限の97%前後）に評価を使い、突入電流は上限の7割未満止まり

人が選んだコーナーを使わない4次元の攻撃

	発見AIの最適解（最悪 +142.1%）		人手調整の則C'（切替0.5 V）（最悪 +20.4%）	
	違反を発見	最悪に到達	違反を発見	最悪に到達
無作為抽出	**5／5回**	**0／5回**	**1／5回**	**0／5回**
反証AI 応募時の探索（コーナーなし）	**5／5回**	**0／5回**	**0／5回**	**0／5回**
反証AI 勾配法を追加	**5／5回**	**2／5回**	**0／5回**	**0／5回**
反証AI 制約ごとに攻撃	**5／5回**	**2／5回**	**3／5回**	**1／5回**
改良した反証AI	**5／5回**	**5／5回**	**3／5回**	**3／5回**

評価20個体（ラテン超方格法8＋ベイズ最適化12）、種5通り。応募時は人が置いた初期点（コーナー4点）を入れた（スライド5・8）
ここではコーナーを入れずAIに選ばせた。違反の大きさは超過率の最大値、最悪は16コーナーの全探索（付録G）

改良した反証AIは、応募時に人が入れたコーナー（+142.1%の個体）に5回中5回到達した

量子化と測定誤差の許容（8ビット・±5 mV）

定数8個の量子化（最終則、公差の16コーナー）

16ビット	**違反 0／16**	余裕 2.6%
12ビット	**違反 0／16**	余裕 2.5%
10ビット	**違反 0／16**	余裕 2.7%
8ビット	**違反 0／16**	余裕 3.1%

0～3.3 Vを0～（2のb乗−1）に対応（応募書と同じ方式）
8ビットでは電流指令のずれが最大5.9%
最も厳しい制約が充電時間に移動

バンク電圧の測定誤差（最も厳しい3個体）

+10 mV	**違反（入力ピーク電流 1.014 A、+1.4%）**
+5 mV	**違反なし（余裕 0.6%）**
±2 mV	**違反なし**
−5 mV	**違反なし（余裕 0.4%）**
−10 mV	**違反（充電時間 0.297秒、+6.0%）**

デューティ比の指令に使うバンク電圧の測定値に誤差を加算
電流は電圧差（0.08～0.11 V）で決定
高く読むと電流が増加、低く読むと充電時間が増加

マイコンに持たせる表は8ビットでも成り立つが、バンク電圧は4.4 Vの約0.1%（±5 mV）で測る必要がある

全探索を攻撃側にした10次元の防御

	応募時の最終則	1ラウンド目の則	2ラウンド目の則 ＝10次元で直した則
切替電圧	**0.35 V**	**0.332 V**	**0.300 V**
10次元 1024コーナーの違反	**2／1024**	**64／1024**	**0／1024**
10次元 無作為200個体の違反	**0／200**	**未計算**	**0／200**
4次元 16コーナーの違反	**0／16**	**未計算**	**0／16**

1ラウンド目：効率の高い則（学習個体の平均95.12%）が選ばれたが、
全セル22 mFの64コーナーで充電時間が上限超過。突入電流も最大0.4992 Aで上限の直下

2ラウンド目：違反コーナーを学習個体に加え再探索、
どの検査でも違反0（1024コーナーで上限の2.0%手前）

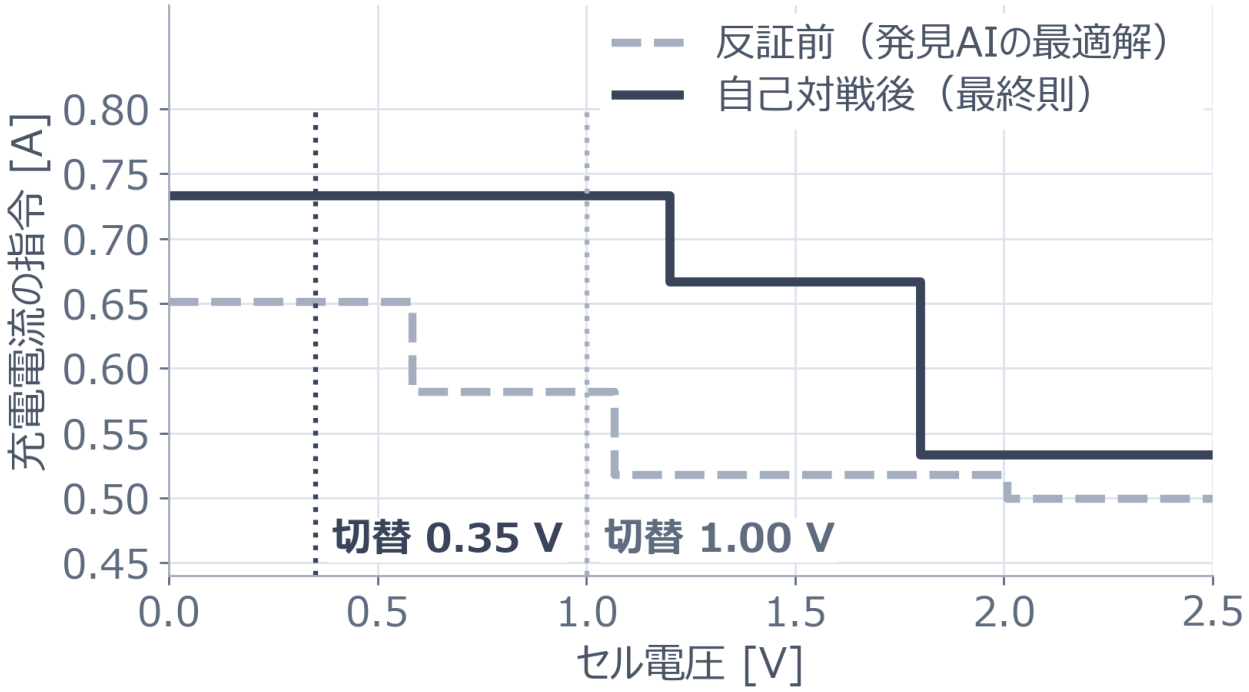
反証AIが攻撃側なら

応募時の最終則から
始めた自己対戦は、
評価40個体の
1ラウンド目の攻撃が
違反を見逃し、
違反の残る則で終了

終了条件の限界

攻撃が通らないことを
終了条件にすると、
攻撃の検出力より
強い保証は出せない

定数8個・16バイトの最終則



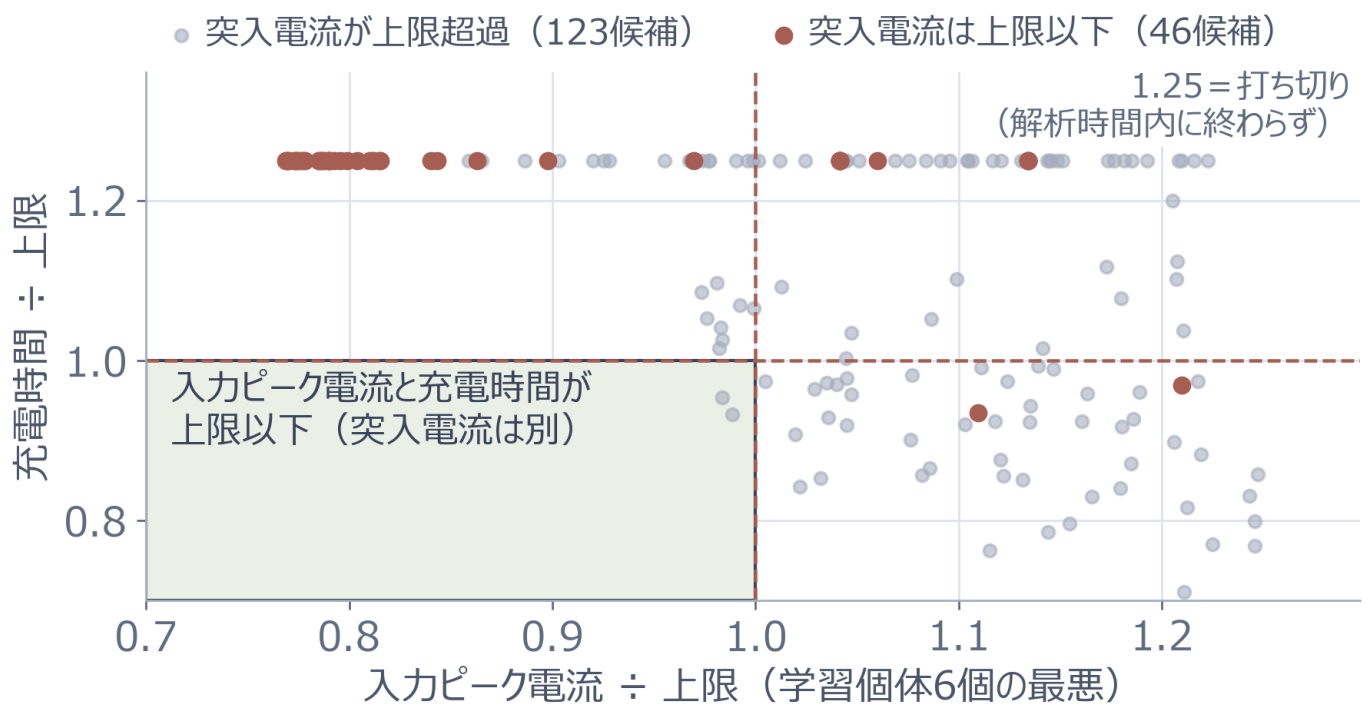
充電則の大きさ（16ビット固定小数点×8個）

16バイト

PIC16F627A のRAM 224バイトの7.1%

- 実行時の処理は比較4回と代入1回
- 浮動小数点の演算は不要
- 切替を1.00 Vから0.35 Vへ前倒し
  電圧差が広がる前に並列化

12次元の自己対戦の防御（169候補）

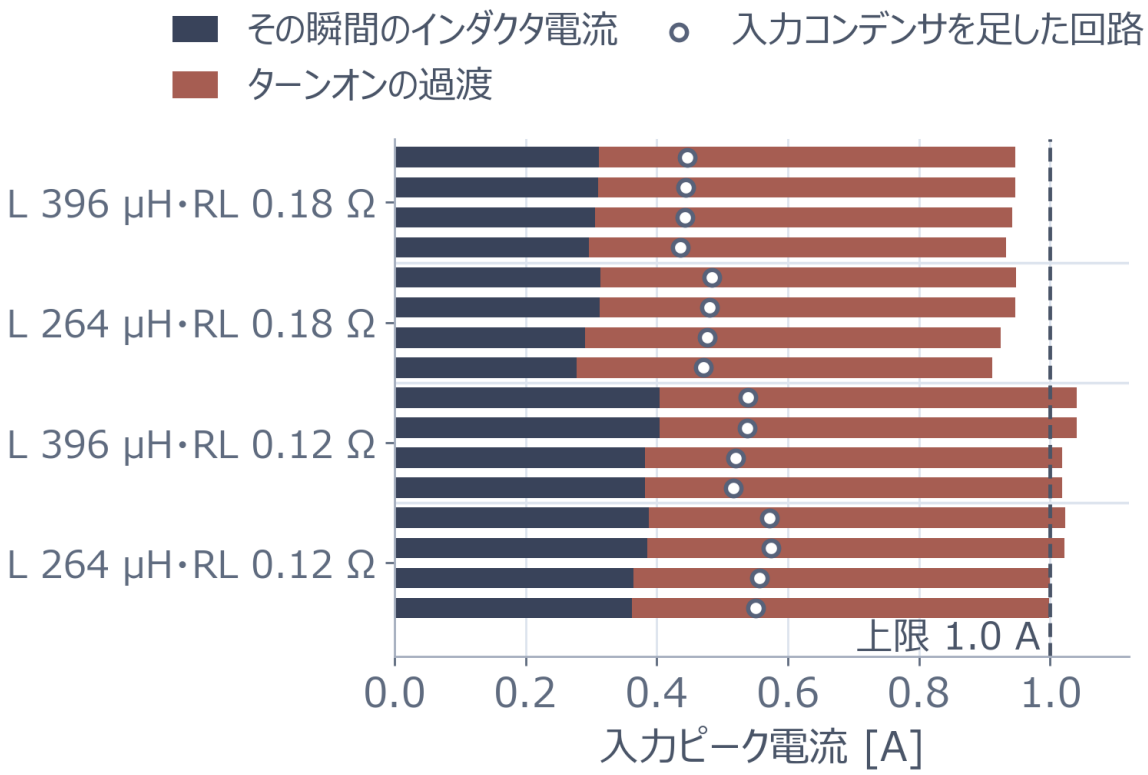


容量の偏った個体で、切替電圧は0.33 V以下に限られた

- 学習個体6個：初期4＋攻撃で見つけた2
- 防御は2回：事前に決めた47候補と、候補数を増やした122候補
- 全学習個体で実行可能な則は0
- 突入電流を守った46候補（赤）のうち
  - 34候補は、第1段で切替電圧に届かない個体があり、6個体とも時間内に終わらない
  - 切替 0.30～0.333 V の12候補、重複を除く5つの入力ピーク電流は上限の1.04～1.21倍
- この範囲を生成AI 72則・無作為 40則で探し直しても実行可能な則は0
  （最良の最悪比は付録U。最悪比は6個体・3制約の 値÷上限 の最大）

解がないことの証明ではない

12次元の入力ピーク電流の中身

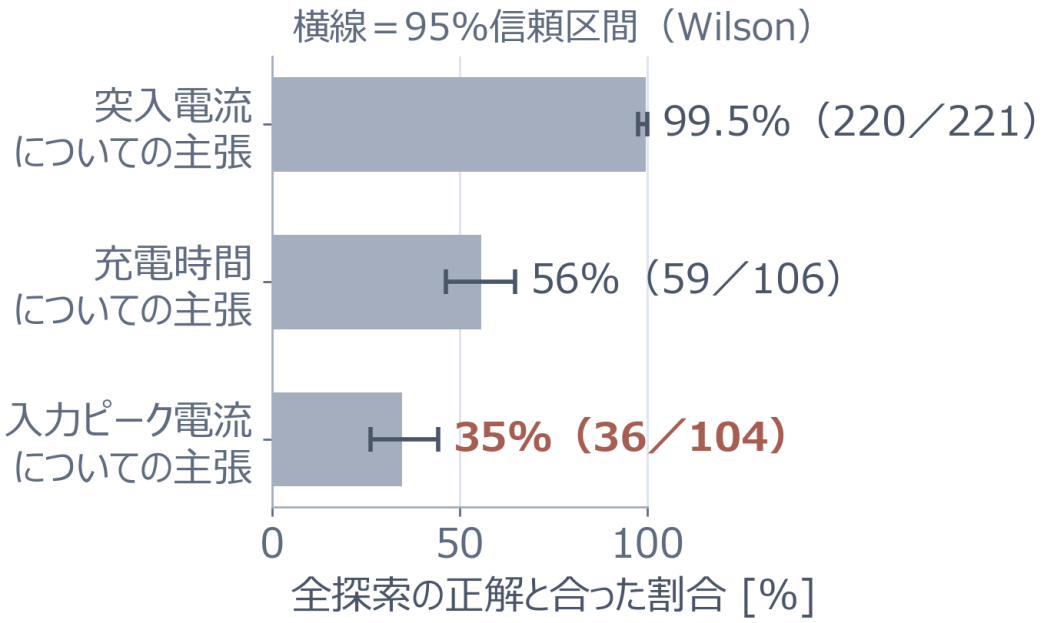


- 12次元の正解から選んだ16コーナー
- 入力ピーク電流＝
  その瞬間のインダクタ電流（0.277～0.404 A）
  ＋ターンオンの過渡（0.633～0.636 A）
- 巻線抵抗 0.12 Ω と 0.18 Ω の差 0.082 A のうち
  0.081 A はインダクタ電流の差
- 事前に予測した介入の向き：
  ゲート抵抗・下側MOSFETの容量・入力コンデンサの
  3種とも16／16コーナーで予測どおり。
  同じスイッチング回路への介入で、
  独立な一致ではない
- 入力コンデンサを足すと 0.436～0.574 A

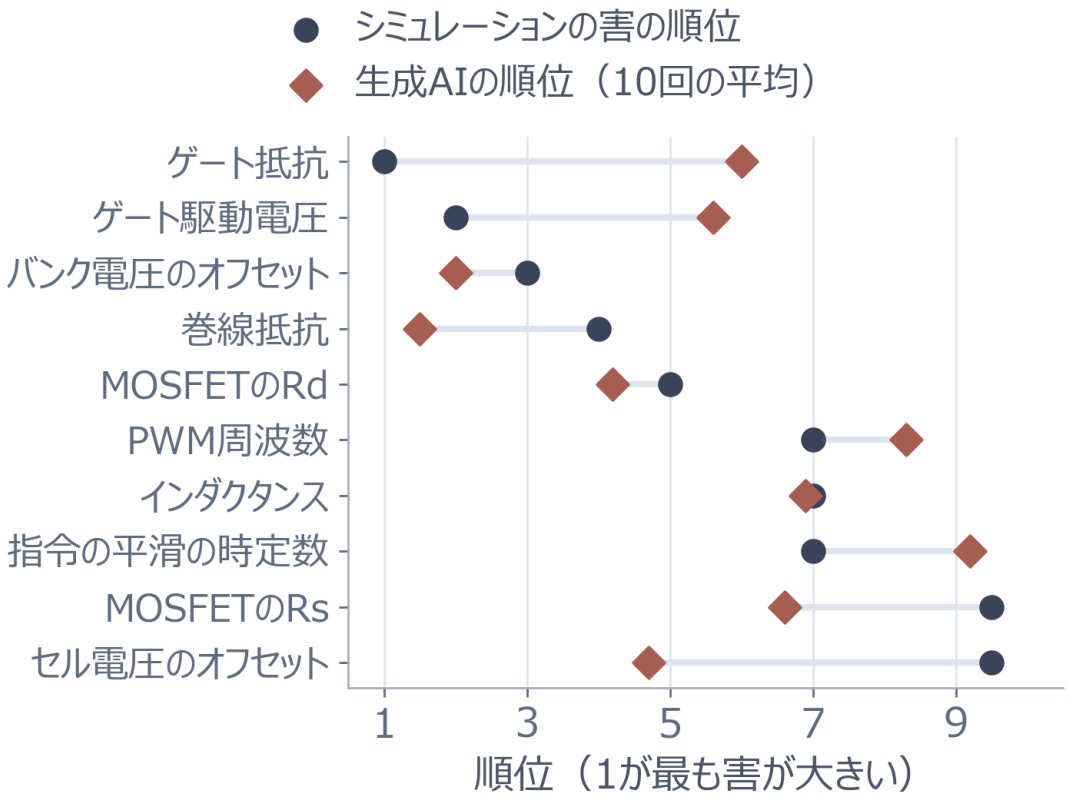
理想電圧源・入力コンデンサなしのモデルでの値

上限1.0 Aは実質、スイッチを入れる瞬間のインダクタ電流を約0.36 A以下にする制約だった

生成AIの理由と範囲外の定数の採点



偶然では違反を含みにくい対象の30回（提案は30回とも含む）
採点は Claude 2組、一致度 κ 0.87（人による照合なし）



提案した違反の理由はほぼ正しく、入力ピーク電流の主張は3分の2が誤りだった

電流フィードバック制御（則は同じ）

比較の範囲（12次元）	10次元で直した則（開ループ）	電流フィードバック
学習個体6個（付録O で同時に満たせず）	満たした個体 4／6	**満たした個体 6／6**
制約ごとに最も厳しい48コーナー	違反 47	**違反 0**
全探索 4096コーナー	違反 2288 時間を延ばすと 2132	**違反 0（測定欠損 0）**
全探索の中の最も厳しい値	入力ピーク電流 1.041 A 充電時間 0.296 s（延長）	**入力ピーク電流 0.991 A** **充電時間 0.271 s**
無作為1000個体（両方で同じ個体）	違反 209	**違反 0（測定欠損 0）**
効率（学習個体A、同じ則どうし）	94.62%	**94.57%**

制御の作り：電流指令＝定数 δ ÷ 公称のループ抵抗。インダクタ電流を測り、差を積分してデューティ比を補正（電流は誤差なく測るモデル）
限定：計算値の幅 ±3.76 mA を引いても全適合（付録T）。オフセット 約 +0.011・−0.014 A 超で最も厳しいコーナーが上限超過

則の定数は変えず、電流フィードバック（制御の定数は予備計算で決定）で12次元の違反が2288 → 0になった

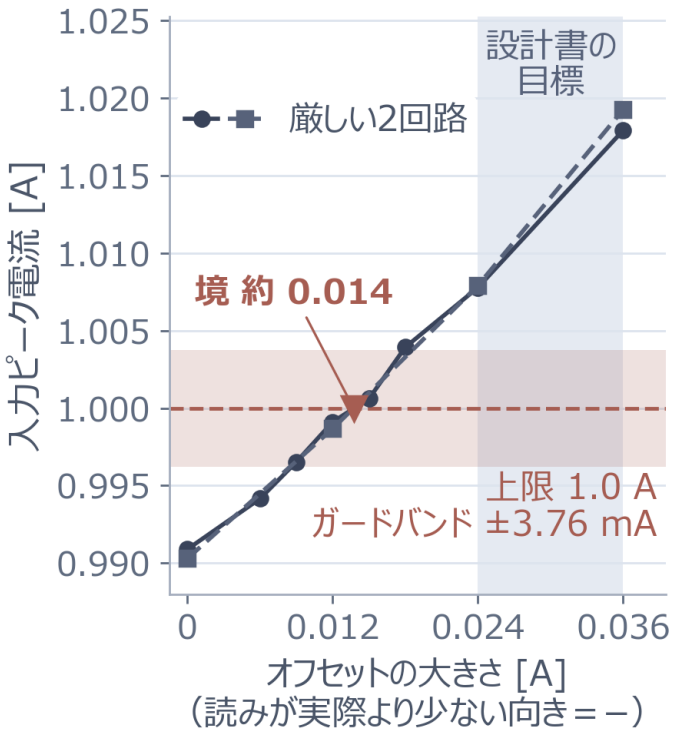
電池の充電時間の代償の内訳

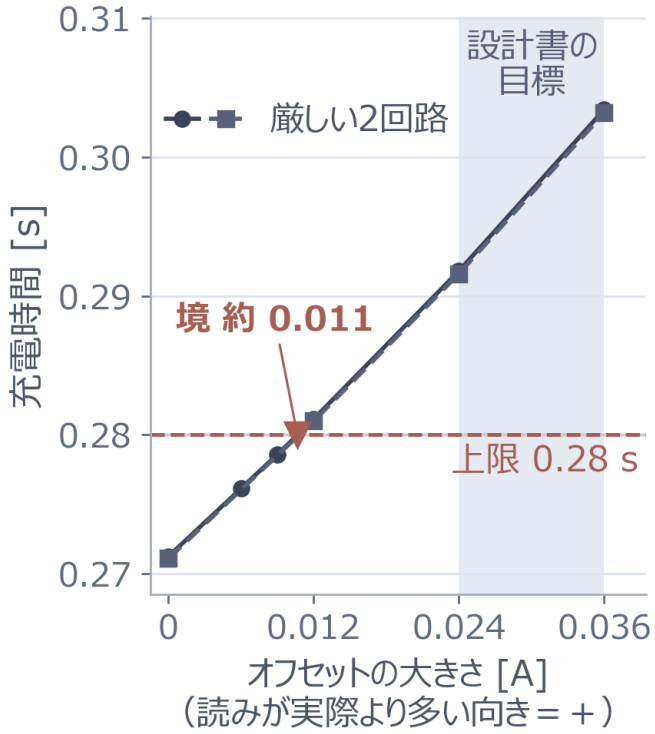
則（† ＝その空間の全コーナーと無作為1000個体で違反0）	充電時間（充電率10〜80%）
公称の個体だけで最適化（ばらつきの中では違反あり）	**34.1 分**
自己対戦の則（乱数の種を変えた3回） †	**85.6·93.2·99.1 分**
コーナーごとに則を選び直せた場合の最悪（上界）	**84.7 分**
環境温度を公称に固定した空間での自己対戦（2回） †	**58.9·62.1 分**
電流を一律に縮める安全率（縮める量が最小、5回） †	**中央値 113.4 分**
制約を一律に締める安全率	**格子の中で違反0にならず（0／5）**

要因を1つずつ公称に固定すると、種による差（約14分）を超えて短くなったのは環境温度（約31分）だけ
PyBaMM の電気化学モデルでの値。手法（ロバスト化の代償・情報の価値）は既知で、この事例の内訳を示すだけ

環境温度を公称に固定すると約31分短く、一律の安全率（中央値）より自己対戦の則が速かった

電流センサに要る精度（反証からの逆算）





- 正解の計算値の幅 ±3.76 mA を引いても4096コーナーすべて適合。厳しい26回路の幅を当てはめた外挿
- オフセットの境：
  少ない向き（−）約 0.014 A
  多い向き（＋）約 0.011 A
  厳しい4回路で見た必要条件
  - 入力電流の平均から推定するなら入力電流の読みで 1.6〜3.6 mA
- デューティ比の平滑の遅れを1／4・1／16 にすると厳しい16回路が上限超過
  定数は時間を縮めた回路モデルで校正、実機では校正し直しが要る（未実施）

設計書の目標 ±0.024〜0.036 A は両側で上限超過

回路＝解析1本（スイッチ抵抗の4通り＝4コーナー分）

電流を誤差なく測るモデルで違反0、オフセット 約 +0.011・−0.014 A 超で最も厳しいコーナーが上限超過

生成AIに足す情報と、防御側の生成AI

攻撃側：記述に足す1文の効果（標的を含んだ回数）

モデル	情報なし	大きさの1文	＋仕組みの1文	判定（大きさ→仕組み）
opus-4-8	8	3	10	増加（p = 0.003）
sonnet-5	5	5	5	条件に届かず（p = 1.00）
haiku-4-5	7	6	5	条件に届かず（p = 1.00）

標的＝入力ピーク電流の上限だけを下げて作った。各10回
無作為に8コーナーを選んでも1回あたり約90%で標的を含む
opus-4-8 でも違反側を多く選ぶ向きは事前の条件に届かず
opus-4-8 に固有の可能性があり、一般の性質とは言えない

防御側：台帳を入力した生成AIの探し直し

探索	絞った範囲の則	実行可能	最良の最悪比
生成AI（台帳を入力）	**72**	**0**	**1.030**
無作為（範囲を絞る）	40	0	1.102
付録O の防御の169候補	5（重複を除く）	0	1.110

絞った範囲＝6個体の突入電流を同時に守れる切替電圧（0.30～0.333 V）
生成AIは10回とも「この形の則では満たせない」と出力した（台帳から読める判断）
有限の候補での結果で、解がないことの証明ではない

切替電圧を絞った112則で探し直しても、6個体を満たす則は0

組の電圧差で第1段を止める条件（開ループ）

検査の方法	結果
防御（ベイズ最適化）	**84候補中8が学習6個体で適合（最良の1つを以下で検査した）**
12次元の全探索 4096コーナー	**充電時間で不適合 256（再現）** **容量が組で最も偏った型 × 巻線抵抗 0.18 Ω**
解析時間を 0.80 s に延長	**256 とも充電時間 0.290〜0.301 s（上限 0.28 s）**
反証AIの攻撃（5回×40個体）	**3回で再現（同じ型、3つとも 256 の中）**
突入電流（オフセット0）	**不適合 0（最大 0.414 A、上限 0.5 A）**
オフセット	**組の電圧差 ±10 mV：新しい不適合は学習個体1・2の各1** **バンク電圧 ±5 mV：新しい不適合は回路1つと学習個体1・2**

条件：$|V1+V2-V3-V4| \geq 0.099$ V で第1段を止める（閾値は予備計算の後に決定）
限定：電圧を誤差なく測り、停止を瞬時に判定する時間を縮めた回路モデル。無作為の個体は未確認

突入電流の不適合は0、学習個体にない組合せの充電時間で4096コーナー中256が不適合（再現）

採点を入力する往復で生成AIが再生成した構造

往復と検査の方法	結果（電流フィードバックなし）
往復の手順	**量子回路を設計させた研究の手順を借用** **評価器の採点と棄却の理由を入力、各回は新しい会話**
生成AI	**claude-opus-4-8、呼び出し21回・9.94 ドル**
学習6個体	**3方針のうち2つが適合（1・2回目の構造）**
反証AIの攻撃（6回目の構造）	**5回すべてで再現：巻線抵抗 0.18 Ω の充電時間**
全探索 4096（8回目の構造）	**巻線抵抗 0.12 Ω の入力ピーク電流で不適合 116（再現）**
オフセット（8回目の構造）	**組の電圧差 ±10 mV で突入電流 最大 0.534 A（上限 0.5 A）**

限定：突入電流の式と、同じ量を表せる語彙を渡した
条件の形は仕様から読める（答えを見ていない別の生成AI 2つが推測できた。誘導の強さ 7／10）
3方針は同じモデルの標本で、独立な再現ではない

採点を入力する往復で学習6個体に届いたが、反証AIと全探索で不適合（検査した構造は別）

組の電圧差の条件と電流フィードバックの組み合わせ

比べたもの	結果（インダクタ電流を測ってフィードバック）
構造	**10次元で直した則の定数で切替電圧だけ 1.0 V ＋組の電圧差 0.099 V で第1段を止める条件＋電流フィードバック**
全探索 4096・反証AIの攻撃	**違反 0（オフセット0）**
インダクタ電流のオフセットの許容範囲	**[−0.010, +0.029] A（29対象）**
比較：電流フィードバックだけ（付録T）	**[−0.014, +0.011] A（厳しい4回路）**
設計書の目標の下端 ±0.024 A	**少ない向きで届かない： 付録T で計算していない8回路の入力ピーク電流 1.009〜1.011 A**

電流センサはフィードバックに使うので必要。入力電流から推定するなら要る精度は 1／D 倍厳しい（付録T）
限定：時間を縮めた回路モデル、制御の定数は付録R のまま。交点は ±0.024・±0.036 A の格子の補間。無作為の個体は未確認

オフセット0では違反0、−0.024 A で8回路が上限超過（境は補間で約 0.010 A）